

VL Reward Model 实验报告

csh / Codex assisted

2026-05-19

1 任务与提交目标

本次考核要求以 Qwen2-VL 或 InternVL2.5-VL 系列模型为 base model，在模型后端添加 score head，将其训练为多模态 reward model，并在 VLRewardBench 上报告：

- base model 在 VLRewardBench 上的分数 $Score_{base}$ ；
- 训练后的 reward model 权重；
- reward model 在 VLRewardBench 上的分数 $Score_{reward}$ ；
- 数据处理、训练参数、实验发现与问题分析。

训练数据唯一硬约束是不使用 VLRewardBench 数据训练。本实验严格将 VLRewardBench 仅用于最终评测。

2 环境与代码

服务器工作目录为 /data4/ljl/csh/vl_reward_work，本轮训练和评测均限制一次最多使用 4 张 RTX 4090 24GB GPU。主要环境如下：

项目	配置
InternVL 环境	/data3/ljl/miniconda3/envs/internvl/bin/python
Qwen 环境	/data3/ljl/miniconda3/envs/qwen25vl/bin/python
InternVL base	/data2/ljl/csh/pretrained_model/InternVL2_5-2B
Qwen base	/data2/ljl/csh/pretrained_model/Qwen2-VL-7B-Instruct
InternVL 脚本	/data4/ljl/csh/vl_reward_work/scripts/internvl_reward.py
Qwen 脚本	/data4/ljl/csh/vl_reward_work/scripts/qwen2vl_reward.py

相对原始尝试，代码层面主要补充了三类能力：第一，修复并扩展 InternVL 的数据准备和 reward forward，避免训练时产生完整 vocab logits；第二，为 Qwen2-VL 增加手写 LoRA、score head 训练与评测脚本，因为当前服务器 Qwen 环境没有可直接使用的 peft/bitsandbytes；第三，补齐两个 base model 的 generative judge 评测入口，并用 4 卡分片评测后合并。

3 数据处理

训练数据来自两部分：

- RLHF-V 已处理偏好对：训练 2,533 条，验证 281 条；
- HuggingFaceH4 rlhf-v_formatted 全量 13 个 parquet shard，共 78,975 条原始样本。

最初只使用了 H4 的少量 shard，并且在 prepare 阶段按 query 文本去重。后来检查发现，同一个 query 可能对应不同图像或不同偏好对，按 query 去重会误删大量有效样本，因此重新下载 13 个 shard，并改为不按 query 去重。最终构造：

文件	样本数
data/processed_h4_30k_nodedup/train_pairs_h4.jsonl	29,000
data/processed_h4_30k_nodedup/val_pairs_h4.jsonl	1,000
data/processed_h4_30k_nodedup/train_pairs_mix.jsonl	31,533
data/processed_h4_30k_nodedup/val_pairs_mix.jsonl	1,281
data/processed/vlrewardbench_eval.jsonl	1,247

为了避免评测泄漏，数据准备时使用 VLRewardBench 的 query 集合做过滤；VLRewardBench 只参与最终 eval，不进入训练或验证。

4 方法

4.1 Base judge

$\text{Score}_{\text{base}}$ 使用原始 base model 直接做 A/B judge：输入图像、问题、Response A、Response B，要求模型只输出 A 或 B，然后和 VLRewardBench label 比较。这个分数不是训练得到的 reward head 分数，而是原模型的 generative judging 能力。

Qwen2-VL 的初始 base judge 评测中发现超长回答会截断掉末尾的 “Answer with exactly one letter” 指令，使模型续写答案而不是判 A/B。因此最终 Qwen base 采用更严格的设置：每个候选回答最多保留 1,200 字符， $\text{max_length}=1536$ ，以保证最终生成提示保留，parse rate 提升到 98.9%。未保护版本 52.13% 只作为诊断结果，不作为主 $\text{Score}_{\text{base}}$ 。

4.2 Reward model

Reward model 对每个候选回答独立打分，而不是同时看 A/B 后生成选择。结构为：

$$s(x, y) = \text{Head}(h_{\text{last}}(x, y)),$$

其中 x 是图像和问题， y 是候选回答， h_{last} 是最后一个有效 token 的隐藏状态，Head 为 Layer-Norm + Linear scalar head。训练目标为 pairwise Bradley – Terry loss：

$$\mathcal{L} = -\log \sigma(s_{\text{chosen}} - s_{\text{rejected}}).$$

两个模型均冻结原 backbone，仅训练 LoRA adapter 和 scalar score head。这样可以在 4090 24GB 上完成训练，也便于保存和提交权重。

5 训练配置

配置	InternVL2.5-2B Reward	Qwen2-VL-7B Reward
训练集	H4 30k no-dedup + RLHF-V mix	H4 30k no-dedup + RLHF-V mix
训练样本	31,533	31,533
验证样本	1,281	1,281
epoch	1	1
GPU	4 × RTX 4090 24GB	4 × RTX 4090 24GB
max length	1536	768
图像设置	max_num=4	min_pixels=50176,max_pixels=200704
LoRA rank / alpha	16 / 32	8 / 16
LoRA 层	language layer 8 起	language layer 20 起
优化器	AdamW	AdamW
梯度累积	8	8
训练时间	3,201.7 s	2,360.8 s

Qwen2-VL-7B 参数更大，为保证单卡 24GB 可训练，采用更短文本长度、较低 LoRA rank，并只在靠后的 8 层语言层上加 LoRA。InternVL2.5-2B 更轻，因此使用更长上下文和更高 rank。

6 实验过程与发现

实验不是一次成功的，主要经历了以下几步：

实验	VLRewardBench	观察
InternVL frozen score head	46.99%	只训练头部表达力不足，低于 base judge。
InternVL 小规模 H4/ RLHF LoRA	54.61%	LoRA 有效，但数据量和清洗不够。
InternVL base-judge pseudo	59.98%	蒸馏 base judge 有提升，但仍低于强 base judge。
InternVL H4 30k no-dedup LoRA	71.21%	下载全量 H4 shard、修复去重、提高 rank 后显著提升。

Qwen H4 30k no-dedup 66.56%
LoRA

手写 LoRA + score head 后，reward 分数明显高于 base judge。

最关键的两个工程问题是：

- InternVL 直接调用完整模型 forward 会产生 vocab logits，显存占用很高；改成只取 hidden states、不走 lm head 后，4 卡训练稳定。
- Qwen 环境缺少常用 LoRA 依赖，因此实现了轻量 LoRALinear 包装，只替换目标 language projection 层，避免引入额外安装风险。

7 最终结果

模型	Score _{base}	Score _{reward}	提升
Qwen2-VL-7B-Instruct	43.14%	66.56%	+23.42
InternVL2.5-2B	64.80%	71.21%	+6.42

其中 base score 均为原始模型直接 A/B judge，不训练 score head；reward score 为训练后的 scalar reward model 对 A/B 分别打分后的准确率。两个 reward model 都超过了各自 base judge，其中 InternVL2.5-2B reward 也高于考核文档给出的实验室预先结果 64.8%，Qwen2-VL-7B reward 高于文档中的 51.2% 参考结果。

训练日志中的验证集表现如下：

模型	train acc	val acc	val margin	step
InternVL2.5-2B Reward	68.89%	74.24%	1.1585	986
Qwen2-VL-7B Reward	61.34%	65.42%	0.3812	986

8 权重与结果文件

项目	路径
InternVL best check-point	/data4/ljl/csh/vl_reward_work/outputs/internvl25_2b_lora_reward_h4mix30k_r16_l8_len1536_no_logits_4g/reward_lora_best.pt
Qwen best check-point	/data4/ljl/csh/vl_reward_work/outputs/qwen2vl7b_lora_reward_h4mix30k_r8_l20_len768_4g/reward_lora_best.pt
InternVL base eval	/data4/ljl/csh/vl_reward_work/results/base_judge_internvl25_2b_max4_rerun_20260519.json
Qwen base eval	/data4/ljl/csh/vl_reward_work/results/base_judge_qwen2vl7b_len1536_clip1200_rerun_20260519.json

InternVL reward eval	/data4/ljl/csh/vl_reward_work/results/internvl25_2b_lora_reward_h4mix30k_r16_l8_len1536_no_logits_4g_vlrewardbench.json
Qwen reward eval	/data4/ljl/csh/vl_reward_work/results/qwen2vl7b_lora_reward_h4mix30k_r8_l20_len768_4g_vlrewardbench.json

9 结论与后续改进

本实验完成了 Qwen2-VL-7B 和 InternVL2.5-2B 两个 backbone 的 base 评测、reward model 训练、权重保存与 VLRewardBench 评测。最终 InternVL reward 达到 71.21%，Qwen reward 达到 66.56%。从实验过程看，数据规模、去重策略、是否避免完整 lm head logits、LoRA 覆盖层数和上下文长度是影响结果的关键因素。

后续如果继续提升，优先方向是：对 Qwen 使用更长训练上下文和更大 LoRA rank；引入更强的 hard negative mining；对不同来源数据做重加权，尤其针对 wildvision-battle 这类开放式偏好数据；同时尝试把 base generative judge 的解释蒸馏为 reward 模型的辅助训练信号，而不是只蒸馏最终 A/B 标签。